

INLP 2026 — HW3 Report

111550132 張家睿

Q1. Method Description (5%)

整體 Pipeline

最終提交的 pipeline 不使用 retriever，而是把每題完整 15 個 candidates 直接交給開放權重 LLM，由 LLM 一次性挑出 top-5 evidence。所用模型為 Gemma-4-31B-it (31B 參數；呼叫 NVIDIA NIM API，模型為開源模型)。

question + 15 candidates (text_quotes + img_description) → 套用 prompt template → Gemma-4-31B-it 生成 5 個 quote_id → 正規表示式抽取 ID，依輸出順序作為 ranked top-5 提交。

主要 idea

任務有兩個關鍵特性，讓 retrieval 反而是「不必要的瓶頸」：

1. 每題候選池極小 (≈ 15)，遠小於一般 RAG 的數萬 chunks。即便不截斷文本，整題 prompt 仍可在 LLM context window 範圍內。
2. evidence selection 依賴細節推理（比較數字、找跨段落 references 等），這正是 LLM 比 dense embedding 拿手的場景。

因此採用「retrieve-then-rank」改為「LLM-as-selector」：跳過 retriever，由 LLM 直接做 relevance ranking。

Evidence preprocessing

- 文本 candidates：原樣傳入不截斷，使 LLM 取得完整上下文。
- 圖片 candidates：採用 dataset 已附的 img_description（不重新跑 VLM）。img_description 已是高品質自然語言描述，混在 text candidates 中以同等形式呈現給 LLM，模型用 ID prefix (text* / image*) 自然區辨 modality。Evidence 統一以 [quote_id]: content 格式列出。

Prompt

You are an expert retrieval assistant. I will provide you with a question and a list of evidence items. Your task is to analyze the evidence and extract the top 5 most important evidence IDs that best answer the question.

Question: {question}

Evidence Items:
{candidates}

You must extract and rank exactly 5 evidence IDs in descending order of importance. Even if you think fewer than 5 items are relevant, you MUST fill all 5 spots with your best guesses. DO NOT output fewer than 5 IDs. Output ONLY the 5 IDs separated by spaces (e.g., text1 image3 text5 image2 text10).

Ranking procedure

LLM 輸出的 token 序列即為 ranked list；用正規表示式 `(text|image)[\s\-\_]*(\d+)` 抓取，能容忍 text 1 / text_1 等格式變體。過濾不在 allowed set 的 hallucinated IDs；少於 5 個即重新調用 API。

額外技術

1. Deterministic decoding：temperature = 0.0 + top_p = 0.1，使輸出穩定可重現，避免 sampling 造成的 LB 隨機飄移。

2. **enable_thinking=False**：透過 NIM 的 `chat_template_kwargs` 顯式關閉 Gemma 內建 reasoning，避免 `max_tokens=2048` 之輸出預算被 `<think>` token 佔據。
3. **Min-quotes retry loop**：若單次回應解析出之有效 ID 數 < 5 (`min_quotes=5`)，自動重試最多 12 次並指數型 backoff，最終取所有 attempts 中解析到最多 ID 之回應。此設計能補救偶發 API timeout / 空回應 / 格式錯誤造成的 evidence 漏失。
4. **Evidence modality 過濾**：觀察 train 後得到硬規則 — `evidence_modality_type` 只含 `text` 之題目，gold 100 % 落在 `text*`；只含 `table / figure / chart` 之題目，gold 100 % 落在 `image*`。據此於送入 LLM 前 **prune 掉另一型態之 candidates**：
 - `evidence_modality_type` 含 `text` 不含 `image-like` → 移除全部 `image candidates`
 - `evidence_modality_type` 含 `image-like` 不含 `text` → 移除全部 `text candidates`
 - 兼有兩者或為空 → 不過濾 (fallback)

Q2. Comparison of Retrieval Methods (5%)

數據

Method	Model	Dev R@5	Public LB	Note
BM25	rank_bm25 (Okapi)	0.7364	—	baseline
Dense	BAAI/bge-m3 (dense)	0.7389	—	single-vec dual encoder
Direct LLM	Gemma-4-31B-it (baseline)	0.8848	0.80970	Simple prompt, default sampling
Own method	Gemma-4-31B-it (refined)	0.9057	0.88597	best — deterministic + retry + modality filter

強弱分析

BM25：詞袋 TF-IDF + 長度正規化。優：CPU 即可、對精確 keyword 命中極快；缺：無法處理同義詞、跨語言、數值/單位推理 — 候選若採用同義表述，將發生 false negatives，無法成功召回。

Dense (BGE-M3)：以 dual-encoder 將問題與候選嵌入至同一向量空間，依 cosine similarity 排序。優：捕捉語意相似性、對 paraphrase robust；缺：對細微差異 (特定數字、實體名) 區辨力弱；`img_description` 中常見的 templated 描述使分數鑑別度降低，產生大量 false positives。

Direct LLM (baseline)：直接把 15 個 candidates 餵給 Gemma-4-31B-it 並用簡單 prompt 要求挑出 top-5。優：跳過 retriever 之 false negative，將 ranking 交由具推理能力之 LLM；缺：在 default sampling (`temp=0.7`, `top_p≈1.0`) 下，相同設定多次跑分結果 LB 飄移可達 ± 0.5 pp；偶發回應只給 < 5 IDs 之 case 無補救機制。

Own method (refined)：在 Direct LLM 之上層層套疊以下優化 — (i) **deterministic decoding** (`temp=0`, `top_p=0.1`) 鎖死採樣使結果可重現；(ii) **關閉 reasoning** 避免 token budget 浪費；(iii) **min-quotes retry loop** (max 12 attempts) 補救少數 < 4 IDs 之 case；(iv) **permissive regex + 無 padding** 容忍輸出格式變體且不亂猜補位；(v) **evidence modality 過濾** (依 `evidence_modality_type` prune 對立 modality candidates) — 單此一項即 +1.39 pp LB (0.87211 → 0.88597)。Dev R@5 略升 (0.8858 → 0.9057)，LB 共提升 7.63 pp。

為何 LLM-based 大幅領先 retrieval

1. 候選池只有 15：retrieval 的高 recall 在大型 corpus 才重要；此處 LLM 已能在 15 中做全比較。
2. 跨 modality 比較：retrieval 對「該選 text 還是 image evidence」沒有顯式機制；LLM 在 prompt 內看到兩種 modality 描述，可直接權衡。
3. 組合推理：許多題需要「合併兩段 evidence 才能回答」(e.g. 引用一個表 + 一句敘述)；retrieval 各自打分難以捕捉這種 **jointly informative**；LLM 一次性 ranking 比較合理。
4. **Domain coverage**：BM25/Dense 在 Academic / Tutorial 等 long-form domain 表現顯著弱於 Financial (domain skew)；LLM 不受此影響。

Q3. Multimodal Embedding vs. Text-Description Retrieval for Image Evidence (10%)

兩種方法

1. **(a) Multimodal Embedding:** 用一個跨模態 encoder (這裡選 `google/siglip-so400m-patch14-384` , 1B 參數, 符合 $\leq 80B$) 的 **image tower** 編碼原始圖檔, 與問題用 **text tower** 嵌入後 cosine ranking; text candidates 仍走 text tower。
2. **(b) Text-Description Retrieval:** 把 `img_description` 當成純文字 evidence, 所有 candidates 統一用 text-only encoder (BAAI/bge-m3, dense single-vec) 做檢索; 不接觸原始像素。

實驗結果 (Dev set, 200 題)

Approach	Model	Dev R@5	Text hit-rate	Image hit-rate
(a) Multimodal Embed	SigLIP-so400m (1B)	0.1660	113/199 = 0.568	0/307 = 0.000
(b) Text Description	BAAI/bge-m3 (567M)	0.7389	—	—

(評估範圍 Dev 200 題; Image hit-rate = 0 並非隨機, 是跨模態 cosine 分布錯位造成的系統性偏差, 分析見下。)

選 (b), 因為

1. **對齊現有最佳 pipeline:** 最終的 LLM-selection (Q1) 統一吃 text, `img_description` 直接當 text evidence 餵入; 用 (b) 與整套上下游 consistent。
2. **品質充足:** dataset 提供的 `img_description` 已是 caption-quality 的自然語言, 能傳達圖表中的數值、軸標、趨勢, 這些是 cosine-similarity 圖嵌入較弱的維度。
3. **Scale 一致:** (a) 跨模態 cosine 的 image-vs-text 分數常需 calibration (image-image 與 text-text 分數分布不同); (b) 全 text 統一尺度, rank fusion 更穩。
4. **計算成本低:** text-only 不需處理 14826 張圖片, 跑 dev 200 題只需 ~ 30 s vs SigLIP 數百秒。

兩者性能差異原因 ((a) 較 (b) 表現落後 0.57)

1. **跨模態 cosine 分布錯位, image 系統性排序末端:** SigLIP 的 **image-text cosine** 與 **text-text cosine** 兩個分布之 mean/std 顯著不同 (SigLIP 預訓練即採用 sigmoid loss, 未強制兩 modality 同尺度)。對 candidates 做 z-score normalize 後排序時, **所有 image candidates 系統性落於分布末端**, 導致 top-5 幾乎完全排除 image。實測 image hit-rate = 0/307。此即文獻所稱之 “cross-modal scale gap”, 需 per-modality calibration 方能改善。
2. **圖表類圖片屬於 out-of-distribution (OOD):** HW3 大量出現 charts/tables, SigLIP 預訓練分布以自然影像 (web image-text pairs) 為主, 對「金融折線圖」「演算法流程圖」等 chart-heavy 內容之特徵抽取能力較弱。
3. **文字描述已壓縮 question-relevant signal:** dataset 之 `img_description` 多由強模型生成, 已抽取圖中 key facts (數值、實體、結論); text encoder 對此類 keyword 之命中率較高。
4. **Text encoder 對長 query 容忍度較高:** SigLIP text tower max_position_embeddings 僅 **64 tokens** (實驗中已驗證此 hard limit, 超出即 raise ValueError), 多數 HW3 問題 $\gg 64$ tokens 必須 truncate, 遺失關鍵 token; BGE-M3 支援 8192 tokens 無此限制。
5. **Text hit-rate 僅 0.568** 顯示即便排除 image 崩潰之影響, SigLIP text tower 的語意檢索能力仍不及專為 retrieval 訓練之 BGE-M3。

Q4. Modality Preference Analysis (10%)

觀察一：未加 modality filter 之原始 LLM 行為偏向 text

未啟用 Q1 之 **evidence modality 過濾** 時 (即直接把 15 個 candidates 不過濾餵入 LLM), dev 200 題之 top-5 modality 分布如下:

Source	Text count (%)	Image count (%)	Total
--------	----------------	-----------------	-------

Predicted Top-5 (no filter)	602 (60.7%)	389 (39.3%)	991
Gold answers	199 (39.3%)	307 (60.7%)	506
Bias (pred – gold)	+21.4 pp	-21.4 pp	—

LLM 在無 prior 之 retrieval 中 **系統性偏好 text**：top-5 有 60.7% 為 text，但 gold 只有 39.3%；image evidence 因此 under-retrieved 約 21.4 pp。

偏好成因

1. **Token 佔比不對稱**：text_quotes 中位數 ~ 1100 字元；img_description 中位數 ~ 250 字元。LLM 在 prompt 中接收到的 text token 量約為 image 的 4×，attention 分布因而偏向 text candidates。
2. **Img_description 風格較 templated**：image 描述多以「This figure shows…」 「The chart illustrates…」 起頭，LLM 將之視為敘述性 (descriptive) 而非事實性 (factual)；在 picking task 中傾向選擇含具體數字或引文之 text snippet。

觀察二：加上 modality filter 後分布修正至近乎中性

啟用 Q1 之 modality filter 後，dev 200 題之分布變為：

Source	Text count (%)	Image count (%)	Total
Predicted Top-5 (w/ filter)	372 (37.2%)	627 (62.8%)	999
Gold answers	199 (39.3%)	307 (60.7%)	506
Bias (pred – gold)	-2.1 pp	+2.1 pp	—

Bias 從 ±21.4 pp 收斂至 ±2.1 pp，幾乎完全對齊 gold 分布。

Per-modality hit-rate (filter on)

Modality	Gold count	Hits in top-5	Hit-rate
text	199	154	0.7739
image	307	269	0.8762

Image per-modality hit-rate (0.8762) 高於 text (0.7739)，反映 當 LLM 真的選 image 時挑得相當準；filter 之主要作用即在於 允許 LLM 把原本被 text 擠掉的 image candidates 提到 top-5 之內。

為何 modality filter 同時提升 LB

純單一型態 (text-only 或 image-only) 之題目佔 train 比例頗高 (image-only 樣本占 40.8%)。對這些題目，將對立 modality 之 distractor 整批移除，縮小 candidate pool (15 → 5 或 10)，降低 LLM 比較負擔
實驗驗證：Public LB 由 0.87211 → 0.88597 (+1.39 pp)，與 dev 上之 bias 修正方向一致。

附錄 A：執行與重現

```
# — Reproduce LB-best (Own method, LB 0.88597) —
# 先把 NIM API key 放到 api_key.txt
python HW3_111550132.py --input test.jsonl --output submission.csv \
    --backup gemma_answering_results.json \
    --min-quotes 4 --max-attempts 12

# — 對照 baselines (Q2 / Q3) —
python run_phase1_bm25.py          # BM25
python run_phase2_dense.py         # BGE-M3 dense
python run_phase2b_multimodal.py   # SigLIP (Q3)

# — 評估與診斷 —
```

```
python compute_modality.py      # Q4 modality 分析
python evaluation.py            # Dev Recall@5
```

程式碼結構

- `HW3_111550132.py` : Gemma-4-31B-it direct 15→5 with deterministic decoding + min-quotes retry。
- `run_phase1_bm25.py` / `run_phase2_dense.py` / `run_phase2b_multimodal.py` : Q2、Q3 baseline。
- `dataset.py` / `evaluation.py` / `submission_utils.py` : 共用工具。
- `config.py` : 超參數中央化設定。
- `compute_modality.py` : Q4 modality 分析腳本。