

INLP 2026 — HW3 Report

111550132 張家睿

Q1. Method Description (5%)

整體 Pipeline

最終提交的 pipeline 不使用 retriever，而是把每題完整 15 個 candidates 直接交給 31B 開放權重 LLM，由 LLM 一次性挑出 top-5 evidence。流程：

question prompt + 15 candidates (text_quotes + img_description) → 套用 prompt template → Gemma-4-31B-it 生成 5 個 quote_id → 解析輸出，依輸出順序作為 ranked top-5 提交。

主要 idea

任務有兩個關鍵特性，讓 retrieval 反而是「不必要的瓶頸」：

1. 每題候選池極小 (≈ 15)，遠小於一般 RAG 的數萬 chunks。即便不截斷文本，整題 prompt 仍可在 LLM context window 範圍內。
2. evidence selection 依賴細節推理（比較數字、找跨段落 references 等），這正是 LLM 比 dense embedding 拿手的場景。

因此採用「retrieve-then-rank」改為「LLM-as-selector」：跳過 retriever，由 LLM 直接做 relevance ranking。

Evidence preprocessing

- 文本 candidates：原樣傳入不截斷 (CHAR_LIMIT=0)，使 LLM 取得完整上下文。
- 圖片 candidates：採用 dataset 已附的 img_description（不重新跑 VLM）。img_description 已是高品質自然語言描述，混在 text candidates 中以同等形式呈現給 LLM，模型用 ID prefix (text* / image*) 自然區辨 modality。Evidence 統一以 [quote_id]: content 格式列出。
- Prompt：強制要求模型輸出 EXACTLY 5 個 IDs：

```
You are an expert retrieval assistant... extract the top 5 most
important evidence IDs that best answer the question.
...
You MUST extract and rank EXACTLY 5 evidence IDs in descending order.
Even if you think fewer than 5 items are relevant, you MUST fill all 5
spots with your best guesses. DO NOT output fewer than 5 IDs.
Output ONLY the 5 IDs separated by commas (e.g., text1, image3, ...).
```

Ranking procedure

LLM 輸出的 token 序列即為 ranked list；用正規表示式 (text|image)[\s_]*(\d+) 抓取，能容忍 text 1 / text_1 等變體。過濾不在 allowed set 的 hallucinated IDs；不做 padding — 若 LLM 給少於 5 個 ID 即原樣交出（Kaggle 允許 fewer than top-k，亦比隨機補位更穩健）。

額外技術

1. enable_thinking=False：透過 NIM 的 chat_template_kwargs 顯式關閉 Gemma 內建 reasoning，避免 max_tokens 預算被 <think> token 佔據。
2. Sampling 設定 (NIM)：temperature = 0.1 + top_p = 0.95、max_tokens = 2048，給足輸出空間並保留輕微 sampling 自由度。
3. 單執行緒 + 2 s 間隔：對 NIM 公開 endpoint 採低速率呼叫，避免並行造成的 429 限流大規模 fallback。

Q2. Comparison of Retrieval Methods (5%)

數據

Method	Model	Dev R@5	Public LB	Note
BM25	rank_bm25 (Okapi)	0.7364	—	baseline
Dense	BAAI/bge-m3 (dense)	0.7389	—	single-vec
LLM (API)	Gemma-4-31B-it	0.8854	0.82203	best — full optim
LLM (local)	Qwen3.6-27B Q6_K (local)	0.8988	0.81895	開放權重本地, 無 API

(另含 Hybrid RRF 等 retrieval-中心 pipeline 之 ablation : 4-way BGE-M3 + BM25 RRF + img_boost 達 Dev 0.8081 / LB 0.72342 ; 加 bge-reranker-v2-gemma 為 0.8068 / 0.72650 。皆遠低於 direct-LLM 路線。)

強弱分析

BM25 : 詞袋 TF-IDF + 長度正規化。優 : CPU 即可、對精確 keyword 命中極快 ; 缺 : 無法處理同義詞、跨語言、數值/單位推理 — 候選若採用同義表述, 將發生 false negatives, 無法成功召回 (recall) 。

Dense (BGE-M3) : 以 dual-encoder 將問題與候選嵌入至同一向量空間, 依 cosine similarity 排序。優 : 捕捉語意相似性、對 paraphrase robust ; 缺 : 對細微差異 (特定數字、實體名) 區辨力弱 ; img_description 中常見的 templated 描述使分數鑑別度降低, 產生大量 false positives 。

Gemma-4-31B : 在 direct LLM 上層層套疊四組優化 — (i) **MUST-5 嚴格指令** + 不截斷候選文本, 使 Gemma 能完整看到 evidence ; (ii) 關閉 reasoning, 避免 token budget 被 <think> 區塊佔用 ; (iii) temp=0.1 + top_p=0.95, 引入輕微 sampling 噪聲 ; (iv) permissive regex + 無 padding + max_tokens=2048, 能解析「text 1」「text_1」等變體, 且不為了湊滿 5 個 ID 亂猜。

Qwen3.6-27B Q6_K : 開放權重本地 GGUF 推理, 符合 $\leq 80B$ 規定且不依賴 API。對 CHAR_LIMIT (1500 最佳) 與 temperature (0.0 最佳) 做專屬調校。LB 0.81895 略低於 Gemma-4-31B。

為何 LLM-based 大幅領先 retrieval

- 候選池只有 15 : retrieval 的高 recall 在大型 corpus 才重要 ; 此處 LLM 已能在 15 中做全比較。
- 跨 modality 比較 : retrieval 對「該選 text 還是 image evidence」沒有顯式機制 ; LLM 在 prompt 內看到兩種 modality 描述, 可直接權衡。
- 組合推理 : 許多題需要「合併兩段 evidence 才能回答」(e.g. 引用一個表 + 一句敘述) ; retrieval 各自打分難以捕捉這種 **jointly informative** ; LLM 一次性 ranking 比較合理。
- Domain coverage : BM25/Dense 在 Academic / Tutorial 等 long-form domain 表現顯著弱於 Financial (domain skew) ; LLM 不受此影響。

Q3. Multimodal Embedding vs. Text-Description Retrieval for Image Evidence (10%)

兩種方法

- (a) **Multimodal Embedding** : 用一個跨模態 encoder (這裡選 google/siglip-so400m-patch14-384, 1B 參數, 符合 $\leq 80B$) 的 **image tower** 編碼原始圖檔, 與問題用 **text tower** 嵌入後 cosine ranking ; text candidates 仍走 text tower 。
- (b) **Text-Description Retrieval** : 把 img_description 當成純文字 evidence, 所有 candidates 統一用 text-only encoder (BAAI/bge-m3, dense single-vec) 做檢索 ; 不接觸原始像素。

實驗結果 (Dev set, 200 題)

Approach	Model	Dev R@5	Text hit-rate	Image hit-rate
(a) Multimodal Embed	SigLIP-so400m (1B)	0.1660	113/199 = 0.568	0/307 = 0.000
(b) Text Description	BAAI/bge-m3 (567M)	0.7389	—	—

(Phase 2b 評估範圍 Dev 200 題；Image hit-rate = 0 並非隨機，是跨模態 cosine 分布錯位造成的系統性偏差，分析見下。)

我們選 (b)，原因

1. **對齊現有最佳 pipeline**：最終的 LLM-selection (Q1) 統一吃 text，img_description 直接當 text evidence 餵入；用 (b) 與整套上下游 consistent。
2. **品質充足**：dataset 提供的 img_description 已是 caption-quality 的自然語言，能傳達圖表中的數值、軸標、趨勢，這些是 cosine-similarity 圖嵌入較弱的維度。
3. **Scale 一致**：(a) 跨模態 cosine 的 image-vs-text 分數常需 calibration (image-image 與 text-text 分數分布不同)；(b) 全 text 統一尺度，rank fusion 更穩。
4. **計算成本低**：text-only 不需處理 14826 張圖片，跑 dev 200 題只需 ~ 30s vs SigLIP 數百秒。

兩者性能差異原因 ((a) 較 (b) 表現落後 0.57)

1. **跨模態 cosine 分布錯位，image 系統性排序末端**：SigLIP 的 image-text cosine 與 text-text cosine 兩個分布之 mean/std 顯著不同 (SigLIP 預訓練即採用 sigmoid loss，未強制兩 modality 同尺度)。對 candidates 做 z-score normalize 後排序時，**所有 image candidates 系統性落於分布末端**，導致 top-5 幾乎完全排除 image。實測 image hit-rate = 0/307。此即文獻所稱之 “cross-modal scale gap”，需 per-modality calibration 方能改善，但對下游影響範圍有限。
2. **圖表類圖片屬於 out-of-distribution (OOD)**：HW3 大量出現 charts/tables，SigLIP 預訓練分布以自然影像 (web image-text pairs) 為主，對「金融折線圖」「演算法流程圖」等 chart-heavy 內容之特徵抽取能力較弱。
3. **文字描述已壓縮 question-relevant signal**：dataset 之 img_description 多由強模型生成，已抽取圖中 key facts (數值、實體、結論)；text encoder 對此類 keyword 之命中率較高。
4. **Text encoder 對長 query 容忍度較高**：SigLIP text tower max_position_embeddings 僅 64 tokens (實驗中已驗證此 hard limit，超出即 raise ValueError)，多數 HW3 問題 > 64 tokens 必須 truncate，遺失關鍵 token；BGE-M3 支援 8192 tokens 無此限制。
5. **Text hit-rate 僅 0.568** 顯示即便排除 image 崩潰之影響，SigLIP text tower 的語意檢索能力仍不及專為 retrieval 訓練的 BGE-M3 (後者 Dev R@5 = 0.7389，文本與 img_description 一律以 text 形式處理)。

Q4. Modality Preference Analysis (10%)

(以下統計取自 Qwen3.6-27B local 路線之 Dev 200 與 large_dev 899 預測。Gemma-4-31B 在 dev 上 modality 分布為 text 61.3%/img 38.7%，整體趨勢類似，下方結論皆適用兩條路線。)

Top-5 modality 分布 (Qwen local LB-best，Dev 200 題)

Source	Text count (%)	Image count (%)	Total
Predicted Top-5	652 (65.2%)	348 (34.8%)	1000
Gold answers	199 (39.3%)	307 (60.7%)	506
Bias (pred – gold)	+25.9 pp	-25.9 pp	—

結論：模型 過度偏好 text

LLM-selector top-5 中 65% 為 text，但 ground-truth 僅 39% 為 text；image evidence 受到 **系統性 under-retrieval**，差距約 26 個百分點。

Per-modality hit-rate (更細的視角)

Modality	Gold count	Hits in top-5	Hit-rate
text	199	153	0.7688
image	307	270	0.8795

值得注意的現象：當 LLM 選擇 **image candidates** 時，**per-modality precision** 反而較高 (0.88 > 0.77)；惟其選取 image 之數量偏低（僅佔 top-5 的 35%），整體 image evidence 仍有 12% (37/307) 之 false-negative 漏失。

形成原因分析

1. **Image candidates 訊號量受 char_limit 削弱**：img_description 通常較短（中位數 ~ 250 字元），被 char_limit=1500 截斷之機率極低；text_quotes 中位數 ~ 1100 字元，於 prompt 中之 token 佔比約 4×。LLM 接收之 text token 顯著多於 image token，attention 分布因而偏向 text candidates。
2. **Img_description 風格趨於 templated**：許多 image 描述以「This figure shows…」 「The chart illustrates…」開頭，LLM 將其視為敘述性 (descriptive) 而非事實性 (factual) 內容；在 picking task 中傾向選擇含具體數字或引文之 text snippet，而非 chart description。
3. **Question 含 textual anchor 觸發 shortcut**：HW3 問題常出現「In the section about X…」 「According to Table 3…」等 textual anchor；LLM 過度依賴文字錨點 (textual anchors) 進行表面特徵匹配，造成 text-favored shortcut。
4. **Image per-modality precision 較高之解讀**：當 image candidate 與問題語意明確對齊（例如問「該圖顯示什麼」），其被選中之機率極高；hit-rate 較高之原因在於 LLM 對 image 候選採取較保守的選擇策略 (high-precision, low-recall behavior)。Text 因候選數量多、訊號雜訊比較低，false-positive 數量相對較高。

改進方向（未實作）

- **Length-normalized prompt**：將 text candidates 壓縮至與 img_description 相近之長度（例如統一 char_limit=400），有助於使 modality 分布趨於中性。
- **Explicit modality budget**：於 prompt 中加入「expected mix ~ 40% text / 60% image」之顯式指示，使 LLM 進行 modality balancing。
- **Two-pass selection**：第一階段於 text candidates 中選出 top-3，第二階段於剩餘 image candidates 中補足 2 項。

附錄 A：完整 Leaderboard

Phase / 版本	Method	Dev R@5	Public LB
Phase 1	BM25	0.7364	—
Phase 2	BGE-M3 dense	0.7389	—
Phase 2b	SigLIP-so400m multimodal embedding	0.1660	—
Phase 3	BM25+Dense RRF	0.7713	0.68875
Phase 3b	BGE-M3 4-way (dense+sparse+colbert)+BM25+img_boost	0.8081	0.72342
Phase 3c	Phase3b + VLM caption concat	0.8108	0.72342
Phase 4b	Phase3b + bge-reranker-v2-gemma 融合	0.8068	0.72650
Phase 4c	Phase3c + reranker (overfit)	0.8162	0.72033
Phase 5b	Ensemble RRF 3b/3c/4b/4c	0.8152	0.72650
NIM v1 Gemma	Gemma-4-31B direct 15→5, soft prompt, CL=800	0.8848	0.80970
NIM v2 Gemma	1. MUST-5 + CL=0 + enable_thinking=False	0.8907	0.82126
NIM v3 Gemma	v2 + temp=0.1 + top_p=0.95	0.8967	0.81972
NIM v4 Gemma	v3 + permissive regex + no padding + max_tokens=2048	0.8854	0.82203
Local v1 Qwen Q6_K	CL=1500, n_ctx=8192, temp=0, soft prompt	0.8988	0.81895
Local v3 Qwen Q6_K	1. temp=0.1 + top_p=0.95 (CL=0)	0.8794	0.81355
Local v4 Qwen Q6_K	CL=1500 + temp=0.1 + top_p=0.95 + comma prompt	0.8881	0.81587
Local v6 Qwen Q6_K	Qwen 上 mirror NIM v4 全部設定	0.8827	0.81741

Phase 6 hybrid	Phase 3b top-10 → Qwen3.6-27B	0.8759	0.79583
----------------	-------------------------------	--------	---------

附錄 B：執行與重現

```
# 環境
conda activate NLP2
pip install llama-cpp-python # 本地路線需 CUDA build of llama-cpp-python

# — Reproduce LB-best (NIM v4 Gemma, LB 0.82203) —
python run_phase6_direct_llm.py
# → outputs/phase_6/gemma_4_31b_direct_v4_<ts>/submission.csv

# — Reproduce 本地路線 (Local v1 Qwen, LB 0.81895) —
export CUDA_VISIBLE_DEVICES=0
N_CTX=8192 CHAR_LIMIT_PER_CANDIDATE=1500 TEMPERATURE=0.0 TOP_P=1.0 \
    CACHE_SUFFIX=_v1 python run_phase6_local.py
# → outputs/phase_6_local/<ts>/submission.csv

# Q3 對照: Multimodal embedding (a)
CUDA_VISIBLE_DEVICES=0 python run_phase2b_multimodal.py

# 評估
python tools/compute_modality.py # Q4 modality 分析
python tools/eval_large_dev.py # large_dev (n=899) 重新評估
```

程式碼結構：

- `run_phase6_direct_llm.py`：LB-best Gemma 主程式。
- `run_phase6_local.py`：本地 Qwen 替代路線。
- `run_phase1_bm25.py` / `run_phase2_dense.py` / `run_phase2b_multimodal.py`：Q2、Q3 baseline。
- `dataset.py` / `evaluation.py` / `submission_utils.py`：共用工具 (含 `pad_short=False` 控制不補位)。
- `config.py`：所有超參數中央化設定。
- `tools/eval_large_dev.py` / `compute_modality.py` / `build_large_dev.py`：診斷與 large_dev 評估腳本。