

INLP 2026 — HW3 Report

111550132 張家睿

Q1. Method Description (5%)

整體 Pipeline

最終提交的 pipeline 不使用 retriever，而是把每題完整 15 個 candidates 直接交給 27B 開放權重 LLM，由 LLM 一次性挑出 top-5 evidence。流程：

問題 (q) + 15 candidates (text_quotes + img_quotes 的 img_description) → 套用 prompt template (含 candidate 截斷 char_limit=1500) → Qwen3.6-27B Q6_K GGUF 生成 5 個 quote_id → 依輸出順序作為 ranked top-5 提交。

主要 idea

任務有兩個關鍵特性，讓 retrieval 反而是「不必要的瓶頸」：

1. 每題候選池極小 (≈ 15)，遠小於一般 RAG 的數萬 chunks。把 15 個原文塞入 $\leq 8K$ 的 context 完全可行 ($15 \times 1500 \text{ char} \approx 6K \text{ tokens}$)。
2. evidence selection 依賴細節推理（比較數字、找跨段落 references 等），這正是 LLM 比 dense embedding 拿手的場景。

因此採用 “retrieve-then-rank” 改為 “LLM-as-selector”：跳過 retriever，由 LLM 直接做 relevance ranking。

Evidence preprocessing

- 文本 candidates：原樣傳入，僅截斷至 1500 字元（依 dev 細調，1500 比 800/1200/2000 都好，見 Q1 結尾的 ablation 表）。
- 圖片 candidates：採用 dataset 已附的 img_description（不重新跑 VLM）。img_description 已是高品質自然語言描述，混在 text candidates 中以同等形式呈現給 LLM，模型用 ID prefix (text* / image*) 自然區辨 modality。
- Prompt：固定 system-like instruction，列出所有 candidates，要求輸出「space-separated 5 個 IDs，不解釋」。

```
Pick exactly 5 candidates most useful for answering the question.
Output ONLY 5 IDs separated by spaces, in order of relevance.
Example: text3 image2 text5 text1 image4
```

Ranking procedure

LLM 輸出的 token 序列即為 ranked list；用 regex (text|image)\d+ 抓取，過濾掉不在 allowed set 的 hallucinated IDs；若數量不足 5，補上 candidate pool 前若干個作 fallback。Temperature = 0 確保可重現。

額外技術

1. Reasoning bypass：Qwen3.6-27B 預設 chat template 會於 assistant 段落起始處插入 <think>\n token，迫使模型先進行 reasoning。max_tokens=64 之預算不足以涵蓋完整 <think> 區塊，導致 reasoning token 佔用全部 output budget，最終輸出被截斷 (truncated) 且不含實際答案 (早期版本 LB=0.32049 即源於此)。解法為手動組裝 chat template，預先填入空的 <think>\n\n</think>\n\n，使模型直接略過 reasoning 階段。

```
prompt = (
    "<|im_start|>user\n" + user + "<|im_end|>\n"
```

```

"<|im_start|>assistant\n"
"<think>\n\n</think>\n\n" // ← 略過 reasoning
)

```

2. **Char-limit sweep**：依 dev 結果，CHAR_LIMIT_PER_CANDIDATE = 1500 為最佳值。

CHAR_LIMIT	Dev Recall@5	Public LB	Note
800	0.8659	0.81278	初版
1500	0.8988	0.81895	best
2000	0.8977	0.81818	略遜於 1500

3. **Local GGUF inference**：用 llama-cpp-python (CUDA build) 載入 Q6_K 量化 (22 GB)，單卡 RTX 4090 全 layers 上 GPU，n_ctx=8192，n_batch=512。Test 1798 題約 27 分鐘完成 (≈ 1.0 s/sample)。

4. **Resumable cache**：以 q_id 為 key 存 JSON，每 25 題自動寫盤，crash 後可從中斷處 resume。dev 與 test 共用同份 cache 但以 split set 過濾避免 q_id 撞號。

Q2. Comparison of Retrieval Methods (5%)

數據

Method	Model	Dev R@5	Public LB	Note
BM25	rank_bm25 (Okapi)	0.7364	—	baseline
Dense	BAAI/bge-m3 (dense)	0.7389	—	single-vec
direct LLM	Gemma-4-31B-it (NIM)	0.8848	0.80970	純 LLM 15→5
Ours	Qwen3.6-27B Q6_K (local)	0.8988	0.81895	best

(另含 Hybrid RRF 等 retrieval-中心 pipeline 之 ablation：4-way BGE-M3 + BM25 RRF + img_boost 達 Dev 0.8081 / LB 0.72342；加 bge-reranker-v2-gemma 為 0.8068 / 0.72650。皆遠低於 direct-LLM。)

強弱分析

BM25：詞袋 TF-IDF + 長度正規化。優：CPU 即可、對精確 keyword 命中極快；缺：無法處理同義詞、跨語言、數值/單位推理 — 候選若採用同義表述，將發生 false negatives，無法成功召回 (recall)。

Dense (BGE-M3)：以 dual-encoder 將問題與候選嵌入至同一向量空間，依 cosine similarity 排序。優：捕捉語意相似性、對 paraphrase robust；缺：對細微差異 (特定數字、實體名) 區辨力弱；img_description 中常見的 templated 描述使分數鑑別度降低，產生大量 false positives。

Direct LLM selection (Gemma-4-31B)：將 15 候選與問題一同輸入 prompt，由 LLM 一次選 5。優：深層推理、跨 candidate 比較、modality 自然融合；缺：依賴 API/GPU、單題 latency 高 (NIM 平均 ~ 3.5 s/題)。

Ours (Qwen3.6-27B Q6_K local)：在 direct-LLM 上施加四項優化 — (i) 開放權重本地推理 (符合 ≤ 80 B 規定，無 API quota)；(ii) reasoning bypass 解決因 reasoning token 佔用導致輸出被截斷 (truncated) 的問題；(iii) CHAR_LIMIT 自 800 提升至 1500，每 candidate 訊息量提升約 2 $\times$ ；(iv) 確定性解碼搭配可恢復 cache。

為何 LLM-based 大幅領先 retrieval

- 候選池只有 15：retrieval 的高 recall 在大型 corpus 才重要；此處 LLM 已能在 15 中做全比較。
- 跨 modality 比較：retrieval 對「該選 text 還是 image evidence」沒有顯式機制；LLM 在 prompt 內看到兩種 modality 描述，可直接權衡。
- 組合推理：許多題需要「合併兩段 evidence 才能回答」(e.g. 引用一個表 + 一句敘述)；retrieval 各自打分難以捕捉這種 jointly informative；LLM 一次性 ranking 比較合理。

4. **Domain coverage** : BM25/Dense 在 Academic / Tutorial 等 long-form domain 表現顯著弱於 Financial (domain skew) ; LLM 不受此影響。

Q3. Multimodal Embedding vs. Text-Description Retrieval for Image Evidence (10%)

兩種方法

1. (a) **Multimodal Embedding** — 用一個跨模態 encoder (這裡選 `google/siglip-so400m-patch14-384` , 1B 參數, 符合 $\leq 80B$) 的 **image tower** 編碼原始圖檔, 與問題用 **text tower** 嵌入後 cosine ranking ; text candidates 仍走 text tower 。
2. (b) **Text-Description Retrieval** — 把 `img_description` 當成純文字 evidence , 所有 candidates 統一用 text-only encoder (BAAI/bge-m3 , dense single-vec) 做檢索 ; 不接觸原始像素。

實驗結果 (Dev set, 200 題)

Approach	Model	Dev R@5	Text hit-rate	Image hit-rate
(a) Multimodal Embed	SigLIP-so400m (1B)	0.1660	113/199 = 0.568	0/307 = 0.000
(b) Text Description	BAAI/bge-m3 (567M)	0.7389	—	—

(Phase 2b 評估範圍 Dev 200 題 ; Image hit-rate = 0 並非隨機, 是跨模態 cosine 分布錯位造成的系統性偏差, 分析見下。)

我們選 (b) , 原因

1. **對齊現有最佳 pipeline** : 最終的 LLM-selection (Q1) 統一吃 text , `img_description` 直接當 text evidence 餵入 ; 用 (b) 與整套上下游 consistent 。
2. **品質充足** : dataset 提供的 `img_description` 已是 caption-quality 的自然語言, 能傳達圖表中的數值、軸標、趨勢, 這些是 cosine-similarity 圖嵌入較弱的維度。
3. **Scale 一致** : (a) 跨模態 cosine 的 image-vs-text 分數常需 calibration (image-image 與 text-text 分數分布不同) ; (b) 全 text 統一尺度, rank fusion 更穩。
4. **計算成本低** : text-only 不需處理 14826 張圖片, 跑 dev 200 題只需 ~ 30s vs SigLIP 數百秒。

兩者性能差異原因 ((a) 較 (b) 表現落後 0.57)

1. **跨模態 cosine 分布錯位, image 系統性排序末端** : SigLIP 的 **image-text cosine** 與 **text-text cosine** 兩個分布之 mean/std 顯著不同 (SigLIP 預訓練即採用 sigmoid loss , 未強制兩 modality 同尺度) 。對 candidates 做 z-score normalize 後排序時, **所有 image candidates 系統性落於分布末端**, 導致 top-5 幾乎完全排除 image 。實測 image hit-rate = 0/307 。此即文獻所稱之 “cross-modal scale gap” , 需 per-modality calibration 方能改善, 但對下游影響範圍有限。
2. **圖表類圖片屬於 out-of-distribution (OOD)** : HW3 大量出現 charts/tables , SigLIP 預訓練分布以自然影像 (web image-text pairs) 為主, 對「金融折線圖」「演算法流程圖」等 chart-heavy 內容之特徵抽取能力較弱。
3. **文字描述已壓縮 question-relevant signal** : dataset 之 `img_description` 多由強模型生成, 已抽取圖中 key facts (數值、實體、結論) ; text encoder 對此類 keyword 之命中率高。
4. **Text encoder 對長 query 容忍度較高** : SigLIP text tower max_position_embeddings 僅 **64 tokens** (實驗中已驗證此 hard limit , 超出即 raise `ValueError`) , 多數 HW3 問題 $\gg 64$ tokens 必須 truncate , 遺失關鍵 token ; BGE-M3 支援 8192 tokens 無此限制。
5. **Text hit-rate 僅 0.568** 顯示即便排除 image 崩潰之影響, SigLIP text tower 的語意檢索能力仍不及專為 retrieval 訓練的 BGE-M3 (後者 Dev R@5 = 0.7389 , 文本與 `img_description` 一律以 text 形式處理) 。

Q4. Modality Preference Analysis (10%)

Top-5 modality 分布 (最佳 pipeline, Dev 200 題)

Source	Text count (%)	Image count (%)	Total
Predicted Top-5	652 (65.2%)	348 (34.8%)	1000
Gold answers	199 (39.3%)	307 (60.7%)	506
Bias (pred – gold)	+25.9 pp	-25.9 pp	—

結論：模型 過度偏好 text

LLM-selector top-5 中 65% 為 text，但 ground-truth 僅 39% 為 text；image evidence 受到 **系統性 under-retrieval**，差距約 26 個百分點。

Per-modality hit-rate (更細的視角)

Modality	Gold count	Hits in top-5	Hit-rate
text	199	153	0.7688
image	307	270	0.8795

值得注意的現象：當 LLM 選擇 **image candidates** 時，**per-modality precision** 反而較高 (0.88 > 0.77)；惟其選取 image 之數量偏低（僅佔 top-5 的 35%），整體 image evidence 仍有 12% (37/307) 之 false-negative 漏失。

形成原因分析

- Image candidates 訊號量受 char_limit 削弱**：img_description 通常較短（中位數 ~ 250 字元），被 char_limit=1500 截斷之機率極低；text_quotes 中位數 ~ 1100 字元，於 prompt 中之 token 佔比約 4×。LLM 接收之 text token 顯著多於 image token，attention 分布因而偏向 text candidates。
- Img_description 風格趨於 templated**：許多 image 描述以「This figure shows…」 「The chart illustrates…」開頭，LLM 將其視為敘述性 (descriptive) 而非事實性 (factual) 內容；在 picking task 中傾向選擇含具體數字或引文之 text snippet，而非 chart description。
- Question 含 textual anchor 觸發 shortcut**：HW3 問題常出現「In the section about X…」 「According to Table 3…」等 textual anchor；LLM 過度依賴文字錨點 (textual anchors) 進行表面特徵匹配，造成 text-favored shortcut。
- Image per-modality precision 較高之解讀**：當 image candidate 與問題語意明確對齊（例如問「該圖顯示什麼」），其被選中之機率極高；hit-rate 較高之原因在於 LLM 對 image 候選採取較保守的選擇策略 (high-precision, low-recall behavior)。Text 因候選數量多、訊號雜訊比較低，false-positive 數量相對較高。

改進方向 (未實作)

- Length-normalized prompt**：將 text candidates 壓縮至與 img_description 相近之長度（例如統一 char_limit=400），有助於使 modality 分布趨於中性。
- Explicit modality budget**：於 prompt 中加入「expected mix ~ 40% text / 60% image」之顯式指示，使 LLM 進行 modality balancing。
- Two-pass selection**：第一階段於 text candidates 中選出 top-3，第二階段於剩餘 image candidates 中補足 2 項。

附錄 A：完整 Leaderboard

Phase	Method (短描述)	Dev R@5	Public LB
Phase 1	BM25	0.7364	—
Phase 2	BGE-M3 dense	0.7389	—

Phase 3	BM25+Dense RRF	0.7713	0.68875
Phase 3b	BGE-M3 4-way (dense+sparse+colbert)+BM25+img_boost	0.8081	0.72342
Phase 3c	Phase3b + VLM caption concat	0.8108	0.72342
Phase 4b	Phase3b + bge-reranker-v2-gemma 融合	0.8068	0.72650
Phase 4c	Phase3c + reranker (overfit)	0.8162	0.72033
Phase 5b	Ensemble RRF 3b/3c/4b/4c	0.8152	0.72650
Phase 6 (NIM)	Gemma-4-31B direct 15→5	0.8848	0.80970
Phase 6 local	Qwen3.6-27B Q6_K, CL=1500 (best)	0.8988	0.81895
Phase 6 long-ctx	Gemma CL=2000	0.8986	0.79506
Phase 6 (35B-A3B)	Qwen3.6-35B-A3B Q4_K_M MoE	0.8255	— (skip)
Phase 6 hybrid	Phase 3b top-10 → Qwen3.6-27B	0.8759	0.79583

附錄 B：執行與重現

```
# 環境
conda activate NLP2
pip install llama-cpp-python # 需 CUDA build

# Reproduce 最佳結果 (Phase 6 local, LB 0.81895)
export CUDA_VISIBLE_DEVICES=0
N_CTX=8192 CHAR_LIMIT_PER_CANDIDATE=1500 \
python run_phase6_local.py
# → outputs/phase_6_local/<timestamp>/submission.csv

# Q3 對照: Multimodal embedding (a)
CUDA_VISIBLE_DEVICES=0 python run_phase2b_multimodal.py
# → outputs/phase_2b/google_siglip-so400m-patch14-384_<ts>/

# 評估
python tools/compute_modality.py # Q4 modality 分析
```

源碼結構（提交至 E3）：

- `run_phase6_local.py`：最終最佳 pipeline (主程式)。
- `run_phase6_direct_llm.py`：NIM Gemma 版本 (Q2 對照)。
- `run_phase1_bm25.py` / `run_phase2_dense.py` / `run_phase2b_multimodal.py`：Q2、Q3 baseline。
- `dataset.py` / `evaluation.py` / `submission_utils.py`：共用工具。
- `config.py`：所有超參數中央化設定。